



Bakalářská práce

Lukáš Kuhajda

Akademický rok 2018/2019

Obsah

| | | |
|----------|---|-----------|
| 1 | SLAM - Simultaneous Localization and Mapping | 3 |
| 1.1 | Úvod | 3 |
| 1.2 | Historie | 3 |
| 1.3 | Formulace a struktura SLAM | 3 |
| 1.3.1 | Legenda | 3 |
| 1.3.2 | Pravděpodobnostní SLAM | 4 |
| 1.3.3 | Struktura pravděpodobnostního SLAMu | 4 |
| 1.4 | Řešení problému SLAM | 5 |
| 1.4.1 | EKF-SLAM | 5 |
| 1.5 | Rao-Blackwellizedův částicový filtr (RBPF) | 6 |
| 1.6 | Výpočetní složitost | 7 |
| 1.6.1 | Rozšířený stav | 7 |
| 1.6.2 | Oddělné aktualizace | 8 |
| 1.6.3 | Rozčlenění stavového prostoru | 8 |
| 1.6.4 | Globální submapy | 9 |
| 1.6.5 | Submapy vztažné | 9 |
| 1.7 | Asociace dat | 9 |
| 1.7.1 | Validace várky dat | 9 |
| 1.7.2 | Popis vzhledu | 9 |
| 1.7.3 | Multihypoziční asociace dat | 9 |
| 1.8 | Reprezentace prostředí | 10 |
| 1.8.1 | Částečná pozorovatelnost a zpožděné mapování | 10 |
| 1.8.2 | 3D SLAM | 10 |
| 1.8.3 | SLAM orientovaný pomocí trajektorie | 10 |
| 1.8.4 | Vložené pomocné informace | 10 |
| 1.8.5 | Dynamická prostředí | 11 |
| 2 | Improved techniques for grid mapping with Rao-Blackwellized particle filters | |
| | GMAPPING | 12 |
| 2.1 | Úvod | 12 |
| 2.2 | Mapování pomocí RBPF | 12 |
| 2.3 | RBPF s vylepšenými návrhy a adaptivním převzorkováním | 12 |
| 2.4 | Složitost | 13 |
| 3 | Real-Time Loop Closure in 2D LIDAR SLAM | |
| | CARTOGRAPHER | 14 |
| 3.1 | Úvod | 14 |
| 3.2 | System overview | 14 |
| 3.3 | Local 2D SLAM | 14 |
| 3.4 | Closing loops | 15 |
| 4 | A Flexible and Scalable SLAM System with Full 3D Motion Estimation | |
| | Hector SLAM | 17 |
| 4.1 | Úvod | 17 |
| 4.2 | System overview | 17 |
| 4.3 | 2D SLAM | 17 |

| | | |
|-----|-------------------------------|----|
| 4.4 | 3D State Estimation | 18 |
|-----|-------------------------------|----|

1 SLAM - Simultaneous Localization and Mapping

1.1 Úvod

Simultaneous localization and mapping, v překladu simultánní lokalizace a mapování (SLAM) je problém, při kterém řešíme otázku, zda-li dokáže robot, umístěný do neznámého prostředí a s neznámou lokací, postupně utvářet mapu svého okolí a zároveň určovat místo, ve kterém se nachází. Řešení tohoto problému je nezbytně nutné pro tvorbu zcela autonomně se pohybujících robotů. Jedná se o aktuální téma vzhledem k trendům moderní doby, kdy dochází k pozvolnému přechodu na samořiditelná auta.

1.2 Historie

Jako počátek, kdy byl daný problém poprvé zíněn, se bere konference Robotics and Automation Conference konaná v roce 1986. Pravděpodobnostní metody byly tehdy ještě velmi nerozvinuté, jak v robotice, tak i v umělé inteligenci, a došlo tak pouze k debatě na dané téma.

K většímu posunu kupředu se dostalo o pár let později, kdy vyšla práce pojednávající o vztahu mezi orientačními body (landmarky) a zmenšení geometrické nepřesnosti. Důležitým prvkem zde bylo zjištění, že mezi odhady landmarků na mapě musí být velký stupeň korelace, přičemž korelace roste s dalšími pozorováními.

Ve stejném období vznikaly základy vizuální navigace a navigace pracující se sonarem s použitím Kalmanova filtru. Práce byly v základu dosti podobné, ukazovaly, že odhady landmarků získané pohybem robota prostředím, jsou v korelaci s ostatními kvůli chybě v odhadu pozice robota a je třeba mít stav složený z pozice robota a landmarků. Vznikal tak však velký stavový vektor s náročností rostoucí v kvadrátu a tendence korelaci landmarků snižovat.

Později došlo ke sjednocení problémů lokalizace a mapování a závěru, že snaha minimalizovat korelaci mezi landmarky byla chybná, naopak bylo v zájmu korelaci co nejvíce zvýšit. Struktura SLAMu, a celkově první použití tohoto akronymu, byla prezentována v roce 1995 na International Symposium of Robotics Research (ISRR). Poté v roce 199 se na ISRR odehrálo první zasedání pojednávající přímo o SLAM a došlo k představení práce dosahující stupeň konvergence mezi SLAMem na Kalmanově filtru a pravděpodobnostními metodami pro lokalizaci a mapování.

1.3 Formulace a struktura SLAM

Jedná se o proces, při kterém robot vytváří mapu prostředí, v němž se pohybuje a na základě mapy určuje svoji pozici v prostoru. Pro určování trajektorie robota a rozložení landmarků není třeba znalosti jeho lokace, neboť odhad těchto parametrů probíhá současně.

1.3.1 Legenda

k ... čas

x_k ... stavový vektor popisující lokaci a orientaci robota

u_k ... vektor aplikovaný v čase $k - 1$ pro dostání robota v čase k na pozici x_k

m_i ... vektor popisující pozici i -tého landmarku, která je brána jako neměnná se v čase

z_{ik} ... pozorování lokace i -tého landmarku z robota v čase k

$x_{0:k}$... historie umístění robota
 $u_{0:k}$... historie vstupních dat pro pohyb robota
 $z_{0:k}$... množina pozorování landmarků
 m ... množina landmarků

1.3.2 Pravděpodobnostní SLAM

V této formě je zapotřebí výpočet rozložení pravděpodobnosti

$$P(x_k, m | Z_{0:k}, U_{0:k}, x_0)$$

pro každý časový okamžik k . Jedná se o sdruženou posteriorní hustotu landmarků, stavu vozidla s ohledem na zaznamenané pozorování, řídicí vstupy a zahrnuje čas k s počátečním stavem vozidla. Pro výpočet je využit Bayesův teorém, je tedy potřeba, aby přechodový stavový model a model pozorování popisovaly vliv vstupního řízení a pozorování.

Model pozorování popisuje pravděpodobnost zisku pozorování z_k , pokud známe polohu vozidla a landmarků.

$$P(z_k | x_k, m)$$

Model pohybu vozidla může být popsán jako stavový přechodový model. Předpokládáme přechodový stav jako Markovův proces, při kterém následující stav x_k je závislý pouze na předchozím stavu x_{k-1} a aplikovaném řízení u_k a není tak závislý ani na mapě, ani na pozorování.

$$P(x_k | x_{k-1}, u_k)$$

Máme tak implementaci ve dvoustupňové rekurzivní formě korekce předpovědi.

Aktualizace času:

$$P(x_k, m | Z_{0:k-1}, U_{0:k-1}, x_0) = \int P(x_k | x_{k-1}, u_k) \times P(x_{k-1}, m | Z_{0:k-1}, U_{0:k-1}, x_0) dx_{k-1}$$

Aktualizace měření:

$$P(x_k, m | Z_{0:k}, U_{0:k}, x_0) = \frac{P(z_k | x_k, m) P(x_k, m | Z_{0:k-1}, U_{0:k-1}, x_0)}{P(z_k | Z_{0:k-1}, U_{0:k})}$$

1.3.3 Struktura pravděpodobnostního SLAMu

Model pozorování udává závislost polohy vozidla a pozorování landmarků, sdružená posteriorní pravděpodobnost nemůže být klasicky rozdělena stylem

$$P(x_k, m | z_k) \neq P(x_k | z_k) P(m | z_k),$$

neboť by to vedlo k chybným odhadům. Dalším zdrojem chyb je špatný odhad pozice robota, landmarky jsou ale silně korelované, takže chybný odhad landmarku vůči mapě nevede k chybné poloze dvou landmarků navzájem.

Velmi důležitým poznatkem bylo zjištění, že korelace mezi landmarky monotónně vzrůstá s počtem jejich pozorování (potvrzeno pouze pro lineární Gaussovský případ), tudíž odhad pozice landmarků bude s narůstajícím počtem pozorování monotónně přesnější. Tento jev nastává díky, v podstatě, skoro nezávislému měření relativních pozic mezi landmarky, které jsou zcela nezávislé na natočení vozidla a úspěšné pozorování z tohoto bodu

může nést další nezávislá měření relativních rozložení landmarků.

Pohybem robota v prostoru získává pozorováním novou pozici známých landmarků vůči sobě a dle této informace aktualizuje svoji odhadovanou pozici a také pozici landmarků. Pokud ji nějaký landmark není pozorován, tak je jeho pozice aktualizována dle změny landmarků pozorovaných a pokud jsou zpozorovány landmarky nové, korelují se s existujícími, čímž se vytváří síť. Čím častěji jsou dva landmarky pozorovány při jednom měření, tím je síla korelace větší. Opětovným projížděním mapy tak získáváme přesnější a robustnější mapu.

1.4 Řešení problému SLAM

Při řešení je potřeba adekvátně obsáhnout jak složku modelace prostředí, tak i tvorbu pohybového modelu. Máme řadu možností jak tento problém řešit, například princip Monte Carlo, kdy rozdělujeme hustoty pravděpodobnosti odhadu pozice robota. Další možností je Markovova lokalizace, s tímto přístupem jsme se setkali v pravděpodobnostní formě SLAM. Nejčastěji se setkáváme s reprezentací problému ve formě stavového modelu zatíženého šumem, což vede k použití rozšířeného Kalmanova filtru (v originále *extended Kalman filter* \rightarrow *EKF*). Jinou možností je ještě rozčlenit pohybový model vozidla na vzorky s obecnějším negausovským rozdělením pravděpodobnosti, v tomto případě mluvíme o použití Rao-Blackwellizedova partikulárního filtru.

1.4.1 EKF-SLAM

Popis pohybu vozidla:

$$P(x_k|x_{k-1}, u_k) \leftrightarrow x_k = f(x_{k-1}, u_k) + w_k$$

$f(\cdot)$... funkce modelující pohyb vozidla

w_k ... chyby měření

Q_k ... kovariance

Model pozorování:

$$P(z_k|x_k, m) \leftrightarrow z_k = h(x_k, m) + v_k$$

$h(\cdot)$... geometrické vlastnosti

v_k ... chyby měření

R_k ... kovariance

Tyto dvě definice využijeme v EKF metodě k výpočtu průměru a kovariance sdruženého posteriorního rozložení

průměr:

$$\begin{bmatrix} \hat{x}_{k|k} \\ \hat{m}_k \end{bmatrix} = E \begin{bmatrix} x_k \\ m \end{bmatrix} | Z_{0:k}$$

kovariance:

$$P_{k|k} = \begin{bmatrix} P_{xx} & P_{xm} \\ P_{xm}^T & P_{mm} \end{bmatrix}_{k|k} = E \left[\begin{pmatrix} x_k - \hat{x}_k \\ m - \hat{m}_k \end{pmatrix} \begin{pmatrix} x_k - \hat{x}_k \\ m - \hat{m}_k \end{pmatrix}^T | Z_{0:k} \right]$$

Mezi hlavní problémy této metody se řadí konvergence, výpočetní složitost, sdružování

dat a nelinerita. Prvním z nich, konvergence, se projevuje postupným přechodem determinantu kovarianční matice mapy a všech podkategorií dvojic landmarků k nule. Jednotlivé odchylky landmarků pak konvergují dle původních nepřesností z odhadu pozice robota a jeho pozorování.

Výpočetní složitost je zde brána jako kvadraticky rostoucí s počtem zaznamenaných landmarků, neboť při každém zaznamenaném pozorování se aktualizují již uložené landmarky, tento problém již ale prošel vývojem a existují metody pracující v reálném čase s tisíci landmarky.

Metoda EKF-SLAM je velmi náchylná na chybné spojení pozorování se známými landmarky. Jedná se zejména o problém s uzavřením smyčky, kdy dochází k opětovnému návratu na místo, ze kterého robot začínal nebo ve kterém se již nacházel.

Nelinerita je posledním z významných problémů, kvůli níž můžeme dojít k větším nepřesnostem ve výsledku, neboť EKF-SLAM využívá lineárních modelů pro vyjádření nelineárního pohybu a modelu pozorování, konvergence a konzistence modelu je tedy jistá pouze v lineárním případě.

1.5 Rao-Blackweillizedův částicový filtr (RBPF)

Forma SLAM založená na Rao-Blackwellizedově filtru, jinak nazývaná také jako FastSLAM, je na bázi rekurzivního Monte Carlo modelu a dokáže reprezentovat nelineární stavový model. Je výpočetně nemožné aplikovat na stavový prostor s vysokým počtem dimenzí partikulární filtry, je však možné redukovat velikost vzorků.

Sdružený stav může být jako faktor komponentů vozidla a podmíněných komponentů mapy:

$$P(X_{0:k}, m | Z_{0:k}, U_{0:k}, x_0) = P(m | X_{0:k}, Z_{0:k}) P(X_{0:k} | Z_{0:k}, U_{0:k}, x_0)$$

Rozdělení pravděpodobnosti zde není na jednotlivých pozicích x_k , ale na celou trajektorii $X_{0:k}$ a tím se stávají jednotlivé landmarky na sobě nezávislými, mapa je tedy reprezentována jako soubor nezávislých gaussianů, což znamená lineární složitost oproti kvadratické u formy EKF. Hlavními ukazateli FastSLAMu je mapa, jež je počítána analyticky a vážené vzorky, jimiž je reprezentována trajektorie pohybu. Rekurzivní odhad je proveden partikulárním filtrem pro stav pozice a EKF pro stav mapy.

Zpracování každého landmarku probíhá zvlášť, pozice se aktualizuje stejným způsobem jako v EKF a landmarky, které nebyly zpozorovány, zůstávají na původní pozici a neaktualizují se. Vzájemnou neprovázaností landmarků však vzniká chyba v odhadu, která s časem roste.

V čase $k - 1$, je sdružený stav reprezentovaný jako

$$\{w_{k-1}^{(i)}, X_{0:k-1}^{(i)}, P(m | X_{0:k-1}^{(i)}, Z_{0:k-1})\}_i^V$$

V prvním kroce, pro každou částici vypočítáme návrh distribuce, jež je podmíněná svojí specifickou historií a z ní odebereme vzorek x_k , který je poté sdružen k historii částice $X_{0:k}^{(i)}$. Krokem dva, dle funkce důležitosti, stanovíme váhy vzorků. Třetím krokem je případné převzorkování, které se provádí různě často dle implementace. Krokem posledním je provést EKF update, na každou, již zpozorovanou částici, která je při aktuálním pozorováním zaznamenána.

1.6 Výpočetní složitost

Neobvyklá struktura problému, sdružený stav složený z pozice robota a landmarků, je využita v řadě metod pro redukci výpočetní složitosti, zde má model procesu vliv pouze na stav pozice robota a model pozorování na dvojici robot-landmark. Základním rozdělením metod redukujících výpočetní složitost, je rozlišování optimálních, konzervativních a nekonzistentních metod. První typ, optimální metody, jsou založené na redukci daného výpočtu, výsledkem jsou pak odhady a kovariance, stejně tak, jako je tomu v případě plnohodnotné formy SLAM, rozebírané v předchozích kapitolách. U metod konzervativních dochází k odhadům s vyšší neurčitostí nebo kovariancím, většinou ale, i přes větší nepřesnost, jsou implementovány v reálném použití. Poslední možností jsou nekonzistentní metody a jedná se o algoritmy, které mají nižší neurčitost nebo kovarianci, než algoritmy optimální, ale pro řešení SLAM se v praxi nepoužívají.

Prvním přístupem pro redukci výpočetní složitosti, je omezení požadovaného výpočtu rovnicí aktualizace pozorování. Výpočet časové aktualizace může být omezen metodami využívající rozšířený stav, výpočet stavu pozorování pak metodami oddělovacími rovnice dané aktualizace a obě tyto omezení vedou k redukci výpočtů, typicky jsou to optimální algoritmy. Další možností, je reformulace stavového prostoru do informační podoby, která umožňuje rozdělení výsledné matice s informacemi pro snížení výpočtů, což bývají algoritmy konzervativní. Obvykle je díky nim znatelně redukována výpočetní složitost a stále je zachována dostatečně dobrá odhadovací schopnost. Dalším přístupem je submapping, který rozděluje mapu na regiony, kdy následné aktualizace se konají pouze v dané oblasti a s určitou periodou poté i v rámci celé mapy.

1.6.1 Rozšířený stav

Sdružený stavový vektor x_k v čase k , se skládá z pozice robota a jím zaznamenaných landmarků, kdy model robota ovlivňuje pouze stav pozice, a to vlivem vstupního řízení, stav mapy se tím tedy nemění.

$$x_k = \begin{bmatrix} f_v(x_{vk-1}, u_k) \\ m \end{bmatrix}$$

Pokud při volbě typu SLAM jako EKF, výpočet předpovědi kovariance má kubicky rostoucí složitost s počtem landmarků

$$P_{k|k-1} = \nabla f_x P_{k-1|k-1} \nabla f_x^T + \nabla f_u U_k \nabla f_u^T,$$

to se však dá předělat na formu s pouze lineární složitostí

$$P_{k|k-1} = \begin{bmatrix} \nabla f_{vx} P_{vv} \nabla f_{vx}^T + \nabla f_{vu} U_k \nabla f_{vu}^T & \nabla f_{vx} P_{vm} \\ P_{vm}^T \nabla f_{vx}^T & P_{mm} \end{bmatrix}$$

Přidání nového landmarku má podobný tvar, kdy je nový landmark inicializován jako funkce pozice robota a pozorování a rozšířený stav pak získáme z malého množství existujících stavů

$$x_k^+ = \begin{bmatrix} x_{vk} \\ m \\ g(x_{vk}, z_k) \end{bmatrix},$$

kde $g(x_{vk}, z_k) = m_{new} \rightarrow$ přidání nového landmarku

Rozšíření stavu můžeme aplikovat vždy, když je nový stav funkcí podmnožiny již existujících stavů

$$\begin{bmatrix} x_1 \\ x_2 \\ f(x_2, q) \end{bmatrix},$$

$$\begin{bmatrix} P_{11} & P_{13} & P_{13} \nabla f_{x_2}^T \\ P_{12}^T & P_{23} & P_{23} \nabla f_{x_2}^T \\ \nabla f_{x_2} P_{11}^T & \nabla f_{x_2} P_{32} & \nabla f_{x_2} P_{32} \nabla f_{x_2}^T + \nabla f_q Q \nabla f_q^T \end{bmatrix}$$

1.6.2 Oddělné aktualizace

Jedná se o metody vytvářející optimální odhady. Při implementaci základní podoby aktualizace pozorování, se při každém novém měření aktualizuje jak stav vozidla, tak i mapy, což vede ke kvadratickému nárůstu složitosti s množstvím landmarků. V této metodě si však rozdělíme mapu na menší oblasti, které se aktualizují pouze při jejím průjezdu, zatímco aktualizace celé mapy probíhá s výrazně nižší frekvencí.

Rozlišujeme dva způsoby možné implementace. První z nich pracuje na zmenšené oblasti, ale stále si drží globální referenční souřadnice, jedná se například o algoritmus CEKF (compressed EKF). Druhou možností je tvorba menších map s vlastním souřadnicovým rámcem neopouštějícím danou submapu, což jsou algoritmy CLSF (constrained local submap filter \rightarrow omezený lokální submapový filtr). Pokračovat budeme v rozboru druhé možnosti, neboť je jednodušší a při provádění operací s velkou frekvencí opakování je méně ovlivněna linearizačními chybami, je stabilnější a zabráňuje příliš velkému nárůstu globální kovariance.

Logaritmus submapy se skládá z dvou nezávislých odhadů, které si stále udržuje. Jde o vektory x_G a x_R , kdy x_G je mapa složená z globálně referencovaných landmarků a globálně referencované pozice dané submapy a x_R je lokální submapa s lokálně referencovanou pozicí robota a lokálně referencovanými landmarky. Při získání pozorování se aktualizují pouze landmarky náležící aktuální submapě, ve které se robot nachází. Celkový globální odhad pak získáváme periodicky, zaevidováním submapy do mapy celé a použitím aktualizace omezení na společné vlastnosti obou map.

1.6.3 Rozčlenění stavového prostoru

V této metodě vyjadřujeme stavový odhad (\hat{x}_k) a matici kovariance (P_k) v informační formě pomocí matice informací $Y_k = P_k^{-1}$ a vektoru informací $\hat{y}_k = Y_k \hat{x}_k$. Je výhodné pro mapy s větším měřítkem, kdy spousta nediagonálních prvků bude velmi blízkých nule, což vede k možnosti nastavení těchto prvků na hodnotu nula. Může tím však vznikat malá ztráta optimality při vzniku map.

Rozšíření stavu je rozčleňovací operace vedoucí k přesnému rozčlenění informační formy a má tak ekvivalentní informační formu. Předpokládáme, že podmnožina stavů x_i obsahuje většinu stavů mapy a po rozčlenění dosahuje pouze konstantní složitosti v čase. Můžeme tedy získávat přesné řešení díky rozšiřování stavu novým odhadem pozice robota v každém kroce a zachovat všechny předchozí pozice. Nenulové nediagonální prvky jsou tak pouze ty, které jsou spojené napřímo s měřeními daty.

Dále sem musíme zahrnout marginalizaci, jež je nezbytná pro odstranění předchozích stavů pozice. Máme možnost marginalizovat všechny předchozí stavy, což vede na zhuštěnou

matici informací, a tedy stav, kterého dosáhnout nechceme. Správnou volbou ukotvení pozice můžeme marginalizovat velkou část pozic, aniž bychom vyvolaly nadměrnou hustotu matice informací.

1.6.4 Globální submapy

Rozlišujeme dva základní typy submap a to globálně a lokálně referencované, přičemž oba mají společné, že submapa stanovuje místní souřadnicový rámec a landmarky z jejího okolí jsou odhadovány s ohledem na tento rámec.

Lokální metoda získává odhady pomocí optimálního algoritmu, používajícího pouze lokální landmarky. Tato metoda, i přes výpočetní efektivitu, je při tvorbě struktury submap neoptimální. Globální metoda dokáže z kvadraticky rostoucí složitosti, udělat lineární, či dokonce v čase konstantní složitost. Je to možné díky údržbě a konzervativním odhadům celé mapy. Metoda stojí na odhadování globální pozice submapy v rámci mapy, nevede však ke zmírnění problémů s linearizací, způsobenou velkými nepřesnostmi v odhadu pozic.

1.6.5 Submapy vztažené

Základním rozdílem od metody globálních submap, je absence společného základního rámce. V této metodě se submapy zaznamenávají dle sousedství s ostatními a celou mapu pak můžeme získat souhrnem vektoru cesty. Submapy jsou, díky vyhýbání se globálním spojením, velmi zajímavé z hlediska výpočetní složitosti a problémům týkajících se nelinearity. Velkým kladem je například tvorba lokálně optimální mapy s výpočetní složitostí nezávislou na celkové velikosti mapy a dále, díky úpravám pouze na lokální úrovni, je velmi stabilní.

1.7 Asociace dat

Jedná se velmi důležitý problém, neboť, i když během procesu tvorby mapy dojde pouze k jedné chybné asociaci dat, může to vést k destabilizaci odhadu mapy, často dokonce k pádu celého algoritmu

1.7.1 Validace várky dat

Zprvu se k problému přistupovalo způsobem, kdy se každé jednotlivé zachycení landmarku porovnávalo se všemi odhady nacházejícími se v blízkém okolí. Tento individuální přístup je neproveditelný, pokud je nejistá pozice robota, což je tedy neproveditelné obzvlášť v málo zaplněných prostředích.

1.7.2 Popis vzhledu

Jedním ze způsobů snímání okolí je vidění, kdy zaznamenáváme tvar, barvu, strukturu, a tím dokážeme rozlišovat různé balíčky dat, což využíváme pro přepověd dané asociace, nejčastěji pro problém s uzavřením smyčky. Pokrok této metody přišel, když se začala počítat metrika podobnosti přes sekvenci obrazů, místo původního jednoho.

1.7.3 Multihypoziční asociace dat

Jedná se o metodu nepostradatelnou pro robustní sběr dat v přeplněném prostředí, kdy vytváříme oddělené odhady trasy jízdy pro každou asociční hypotézu. Tato funkce je však

silně limitována dostupným výpočetním výkonem. Dále je metoda vyžívána při implementaci robustního SLAMu ve velkých prostředích, kdy je při uzavírání smyčky vytvořena hypotéza pro smyčku uzavřenou i pro stále neuzavřenou, a tím se bere v potaz, že je prostředí pouze podobné.

1.8 Reprezentace prostředí

Původně se svět modeloval jen jako soubor landmarků majících svůj určitý tvar, později však, zejména ve venkovním, podvodním a podzemním použití, se ukázala tato metoda jako nevyhovující.

1.8.1 Částečná pozorovatelnost a zpožděné mapování

Základním typem pozorování je vidění pomocí kamery nebo nějaký typ dálkového senzoru. Kamera, pokud je na robotovi samostatně, zaznamenává informace neobsahující přesnou vzdálenost objektu. Tento problém měření pomocí senzoru nemá, neboť měření vzdálenosti bývá velmi přesné, za to se pro tento typ vyskytuje problém se šířkou vysílaného paprsku a postraními žlábků. S tímto senzorem nedokážeme jedním pozorováním ani vytvořit přesně položený landmark, neboť tím získáváme negaussovske rozložení pro pozici landmarku a potřebujeme tak větší počet jeho zpozorování pro vytvoření odhadu.

Obecná rozložení umožňují nezpožděné sledování landmarků, zpožděním inicializace však můžeme získat hned gaussovský odhad pozice landmarku, je při tom ale potřeba zaznamenávat pozici robota v každém okamžiku měření, což provedeme rozšířením stavu o vektor pozic. Nejedná se pouze o částečnou pozorovatelnost, ale shromažďování informací a zpoždění rozhodování zvyšuje robustnost procesu.

1.8.2 3D SLAM

Jedná se v podstatě pouze o rozšíření 2D SLAMu, které má však výrazně větší výpočetní složitost a komplikovanější modelování. Rozlišujeme základní tři možnosti. První je klasický 2D SLAM s přidáním schopností vytvářet třetí dimenzi, což se užitečné, pokud se robot pohybuje po rovině. Druhý typ vytváří 3D obraz extrakcí diskretních landmarků a sdruženého odhadu pozice vozidla a mapy. Využití je vhodné v robotech s jedním senzorem, který umožňuje pohyb se šesti stupni volnosti. Poslední možnost se od těch předchozích dost odlišuje. Sdružený stav se totiž skládá z předchozích pozic robota, na každé pozici se udělá 3D sken prostředí a odhad pozice se vyrovná korelací skenů.

1.8.3 SLAM orientovaný pomocí trajektorie

Základní formulací problému je odhadovaný stav, jako pozice robota a zaznamenané landmarky, jinou, novější možností, je odhadovat místo toho trajektorii vozidla. Mapa tak není součástí stavu, každá pozice robota má ale přidružený sken svého okolí, které se pak srovnají a vytvoří globální mapu. Z toho je hned patrný problém, neustálý růst stavového prostoru, který se nijak nepromazává. Využití metody se nachází například při tvorbě topologických map.

1.8.4 Vložené pomocné informace

Ke stavu můžeme připojit rozšiřující data, v tomto případě například teplotu, charakteristiku povrchu a mnoho dalších věcí, které pak napomáhají při tvorbě mapy. Tvorba

takovéto struktury je ale poměrně komplikovaná. Pohybem robota prostředím se ukládají pomocná data do datové struktury tak, že každá buňka v této struktuře je přiřazena danému landmarku v mapě, při aktualizaci jeho pozice se tak přemísťují i přidružené informace.

1.8.5 Dynamická prostředí

Ve světě se setkáváme převážně s dynamicky se vyvíjejícím prostředím, kdy nám do pozorování můžou zasahovat lidé, zvířata nebo třeba nábytek jako židle nebo zaparkovaná auta. Musí se tedy nějak určit, co s takovými objekty bude a jak je za pohyblivé určit. Máme možnost tyto objekty do mapy vůbec nepřidávat, nebo je mít označené za pohyblivé, nesmí se ale stát, že zaznamenáme pohyblivý objekt a uložíme ho jako statický.

Klasická implementace SLAM umí odstranit landmark, i poměrně velké množství landmarků, bez většího vlivu na hodnotu konvergence. To je také využíváno pro úpravu mapy, kdy se odstraňují přebytečné landmarky, které se již na svém místě nenacházejí.

2 Improved techniques for grid mapping with Rao-Blackwellized particle filters

GMAPPING

2.1 Úvod

Jako velice podstatný úkol mobilního robota, bereme schopnost tvorby mapy. Tu můžeme kvalitně vytvářet, pokud máme dobrý odhad pozice a pozici zase správně získávat, pokud máme dostatečně kvalitní mapu. Efektivním řešením je tedy RBPF, který můžeme ještě zlepšit. Jednou možností, je zahrnout přesnost měření do návrhového rozložení, tím získáme přesné vykreslení částic. Druhou možností, je volba vzorkovací techniky udržující rozumný počet částic. Udržíme tak přesnou mapu a snižujeme riziko vyčerpání částice, což je problém vznikající při převzorkování.

Návrhové rozložení získáváme vyhodnocováním pravděpodobnosti pozice robota z kombinace informací ze senzoru a odometrie. Poslední pozorování využíváme pro tvorbu nových částic, odhad stavu tedy provádíme na základě více informací, než jen z odometrie.

2.2 Mapování pomocí RBPF

Základním úkolem je odhad posteriorní pravděpodobnosti a získat tím mapu a trajektorii pohybu, kdy odhad provádíme díky pozorování a informaci z odometrie. Nejprve dochází k odhadu mapy, kterou utváříme z pozorování, poté až trajektorii. Tu získáváme z částic, které měly v rozhodovací době největší pravděpodobnost a každá částice tedy reprezentuje část trajektorie.

Pro výběr správné částice používáme částicový filtr, v tomto případě SIR (Sampling Importance Resampling), který postupně při mapování zpracovává data ze senzoru, poté odometrii a aktualizuje sadu vzorků reprezentující posteriorní pravděpodobnost o mapě a trajektorii.

Celý proces začíná získáním nových částic odběrem vzorků z předchozí generace návrhového rozložení. Dále nastavujeme částicím váženou důležitost, abychom neměli cílové rozložení rovno tomu navrhovanému. Poté dochází k převzorkování, kdy jsou částice přepisovány úměrně jejich váženým důležitostem a nakonec odhad mapy, kdy je pro každou částici, na základě trajektorie vzorku a historie pozorování, vypočítána mapa.

2.3 RBPF s vylepšenými návrhy a adaptivním převzorkováním

Pro získání nové generace částic je třeba vykreslení vzorků z návrhového rozložení, kde platí úměra, čím lepší návrh, tím lepší výsledek. Kdybychom měli návrh rovný cílovému rozložení, měli bychom částice se stejnou váženou důležitostí a nebylo by třeba převzorkování.

Typicky je návrhové rozložení odpovídající odometrickému pohybovému modelu, který však není optimální a to zejména pokud je senzor výrazně přesnější než odhad pozice. Využívá se také vyhlazování pravděpodobnostní funkce, což zabraňuje částicím v okolí významné oblasti, přílišnému poklesu vážených důležitostí. Následkem je ale zkreslení mapy. To se však dá vyřešit zahrnutím posledního pozorování do generování nových vzorků. Díky tomu se můžeme zaměřit na vzorkování ve významné oblasti pro pravděpodobnost pozorování.

Díky zlepšenému návrhu můžeme získávat pro každou částici zvlášť její parametry Gausiánského návrhu a snižuje se také neurčitost výsledných hustot pravděpodobnosti. Porovnávácí pozorování určuje režim významné oblasti pravděpodobnostní funkce pozorování.

Také má většinou funkci maximalizace pravděpodobnosti pozorování, tvorby mapy a počáteční odhad pozice robota. Pokud je pravděpodobnostní funkce vícerežimová, například při uzavírání smyčky, porovnávač vrací pro každou částici nejbližší maximum, což může způsobit vynechání některých maxim v pravděpodobnostní funkci.

Převzorkování je velice důležitým aspektem určujícím výkon částicového filtru, dochází k nahrazování vzorků s nízkou váhou, těmi s váhou vysokou. Je to nezbytný proces, neboť je potřeba konečného počtu částic pro aproximaci cílového rozložení. Může však odtránit dobré vzorky a ochudit tak částice, je proto důležité mít pro převzorkování vhodné rozhodovací kritérium a provádět ho ve správný čas.

$$N_{eff} = \frac{1}{\sum_{i=1}^N (w^{(i)})^2}$$

$w^{(i)}$... normalizovaná váha částice i

N_{eff} - vzorky z cílového rozložení \rightarrow stejné váhové důležitosti (zhoršující se aproximace cílového rozložení \rightarrow větší odchylka vážených důležitostí)

Základní nastavení převzorkování je následující:

$$N_{eff} < N/2$$

N ... počet částic

Dochází tak k výrazné redukci možnosti nahrazení dobrých částic a počtu převzorkování, které se vykonává pouze pokud je potřeba.

Algoritmus probíhá následovně. Zisk odhadu pozice, který je reprezentovaný danou částicí. Dostaneme ho z předchozí pozice částice a odometrického měření od poslední aktualizace. Na základě mapy je provedeno porovnání pozorování z místa úvodního odhadu pozice, kdy se vyhledává pouze v okolí tohoto bodu. V případě selhání se pozice a váhy počítají dle pohybového modelu a následující dva kroky jsou přeskočeny. Prvním z nich vybrání sady vzorků v okolí dané pozice, vypočítání průměrů a kovarianční matice návrhu bodovým hodnocením cílového rozložení v pozici vzorku. Druhým, potenciálně přeskočeným krokem, je zakreslení nové pozice částice z Gaussovské aproximace podle zlepšeného návrhového rozložení. Dále, a to již vždy, dojde k aktualizaci vážených důležitostí a podle zakreslené pozice a pozorování je aktualizována i mapa částice.

2.4 Složitost

Výpočet návrhového rozložení ... $O(N)$

Aktualizace grid mapy ... $O(N)$

Výpočet vah ... $O(N)$

Testování potřeby převzorkování ... $O(N)$

Převzorkování ... $O(N * M)$

M ... velikost grid mapy

3 Real-Time Loop Closure in 2D LIDAR SLAM CARTOGRAPHER

3.1 Úvod

- velké mapy, optimalizované výsledky v reálném čase
- porovnávání scan-to-scan - rychlé hromadění chyb
- porovnávání scan-to-map - omezení chyb, pokud správný odhad pozice a kvalitní data z LIDAR → efektivnost, robustnost
- porovnávání přesnosti pixelů - redukce hromadění lokálních chyb oproti scan-to-scan, náročnější, použití při uzavírání smyčky
- částicové filtry - tvoří stav systému pro každou částici, pro SLAM s grid-mapami s velkým prostorem rychle roste náročnost - řešení - použití systému dělající grid-mapu po čase a ne v každé částici
- SLAM na grafu - kolekce nodů reprezentující pozice a funkce, hrany - omezení získaná pozorováním

3.2 System overview

- real-time 2D mřížková mapa s rozlišením na 5 cm
- submapa do odhadované pozice
- porovnávání vůči poslední submapě → hromadění globálních chyb
- neobsahuje částicový filtr - snížení HW požadavků
- porovnání submapy, dále již nepřepisování - všechny vzniklé připraveny k porovnávání na uzavření smyčky - blízká odhadovaná pozice + dostatečná shoda → přidání omezení uzavření smyčky do optimalizačního problému (odhad pozice) - optimalizace po pár vteřinách - uzavření smyčky je vidět hned

3.3 Local 2D SLAM

- lokální a globální přístup - obě optimalizace pozice (x , y , natočení)
- IMU - inertial measurement unit - odhad směru gravitace, při nerovné ploše
- submapa - kousek světa - lokální chyba porovnávání je odstaněna v globálním přístupu
- Sken - iterativní, zarovnávání skenů a souřadnicových snímků submapy
 - H ... informace o bodech skenu
 - M ... pravděpodobnostní mřížka
 - ξ ... pozice snímání skenu
 - T_ξ ... pozice skenu vůči submapě - transformace - body skenu do submapy
- Submapy - pár skenů do submapy - pravděpodobnostní mřížky mapované z diskrétních bodů mřížky v určitém rozlišení (5 cm)
 - všechny body mřížky - odpovídající pixel ze všech pixelů nejbližší danému bodu
 - přidání skenu do pravděpodobnostní mřížky - výpočet množiny zasažených bodů mřížky a minutých bodů
 - zásah - vložíme nejbližší bod mřížky do množiny zásahů
 - minutí - vložíme bod mřížky sdružený se všemi pixely, které jsou protínány jedním paprskem mezi počátkem skenování a každým snímacím bodem - nepřidáváme body již přidáné do množiny zásahů

- dosud nepozorovaný bod mřížky má přiřazenu pravděpodobnost minutí či zásahu, podle toho jestli je v jedné z těchto množin
- již zpozorovaným bodům aktualizujeme pravděpodobnosti minutí a zásahu
- Ceres scan matching - před vložením do submapy - optimalizace pozice skenu vůči submapě - maximalizace pravděpodobnosti

$$\operatorname{argmin}_{\xi} \sum_{k=1}^K (1 - M(T_{\xi} h_k))$$

3.4 Closing loops

- hromadění lokálních chyb, jen pár snímků za sebou má vždy minimální chybu vůči sobě
- Spare Pose Adjustment - optimalizace pozice snímků
- relativní pozice skenů jsou ukládány, všechny další páry ze skenů a submap jsou brány v potaz při uzavírání smyčky, pokud se submapa nezmění
- běh v pozadí, shoda - relativní pozice uložena mezi optimalizační problémy
- optimalizační problém - nelineární nejmenší čtverce, jednoduché přidávání zbytků - zohlednění dalších dat
- 1x za sekundu Ceres - optimalizace pozice skenu v souladu vůči daným omezením - relativní pozice, kovarianční matice

$$\operatorname{argmin}_{\Xi^m, \Xi^s} 0.5 \sum_{ij} \rho(E^2(\xi_i^m, \xi_j^s, \Sigma_{ij}, \xi_{ij}))$$

- ρ ... ztrátová funkce
- Huberova ztráta - snížení vlivu odlehlých hodnot - přidávají nesprávná omezení do optimalizačního problému - lokálně symetrická prostředí
- branch-and-bound scan matching - větev a mez
- přesnost pixelů

$$\xi^* = \operatorname{argmax}_{(\xi \in W)} \sum_{k=1}^K M_{nearest}(T_{\xi} h_k)$$

- W ... vyhledávací okno
- $M_{nearest}$... rozšíření M na všechny R^2 zaokrouhlením argumentů do nejbližšího bodu mřížky - rozšířená hodnota bodu mřížky ukazuje na odpovídající pixel
- vylepšení účinnosti - úhlový krok takový, aby body skenu v maximálním rozsahu nebyly větší než šířka žádného pixelu - pomalé
- použití branch-and-bound - podmnožiny možností jako uzly ve stromu, kořenový uzel jsou všechny možné řešení (W)
- uzly - potomci dohromady tvoří stejný soubor možností jako rodičovský uzel
- listy - singlety - jediné proveditelné řešení
- stejné řešení jako předchozí přístup pokud je $score(c)$ vnitřních uzlů horní mezí skóre jeho prvků - neexistuje lepší řešení než to doposud známé
- výběr uzlů - prohledávání do hloubky - DFS
- efektivnost závisí na tom jaký je strom - dobrá horní mez a dobré aktuální řešení
- prahová hodnota skóre - pod ní nemáme zájem o dané řešení - nepřidáváme špatné shody jako omezení pro uzavírání smyčky
- často nepřekonáné - snížení výnamu výběru uzlů nebo nalezení počátečního heuristického nastavení
- pořadí průchodu stromu - výpočet horní hranice skóre pro každého potomka, navštívení nejbližšího uzlu - největší mezní počet

- pravidlo větvení - každý uzel popsán pomocí tuple integerů ($c = (c_x, c_y, c_\Theta, c_h) \in \mathbb{Z}^4$)
- - c_h ... výška uzlu - $c_h = 0 \rightarrow$ uzel je list
- výpočet horních mezí - výpočet na vnitřních uzlech - zájem o výpočetní úsilí a kvalitu spojení

$$score(c) = \sum_{k=1}^K \max_{(j \in \bar{W})} M_{nearest}(T_{\xi_j} h_k)$$

- - pro výpočet použití předvypočítaného $M_{precomp}^{ch}$ - můžeme vypočítat skóre s lineární náročností s body skenu
- - - udržení nízké náročnosti - čekání než pravděpodobnostní mřížka není již aktualizována, poté výpočet sbírky předvypočítaných mřížek, znovu a začínáme porovnávat

4 A Flexible and Scalable SLAM System with Full 3D Motion Estimation

Hector SLAM

4.1 Úvod

- nízké výpočetní nároky - malé autonomní systémy
- ne pro uzavírání velkých smyček
- pro rychlý pohyb terénem
- 2D SLAM (soft real time), 3D navigace (hard real time), IMU (inertial measurement unit)
- nerovný povrch - narušil od gmappingu
- frontend SLAM - Hector - odhad pohybu robota v reálném čase
- backend SLAM - optimalizace pozičního grafu vzhledem k omezením mezi pozicemi

4.2 System overview

- pro 6DOF - z 3DOF odhadem naklonění a rotace - navigační filtr spojí měření z inerciální jednotky a dalších senzorů (3D řešení), informace o poloze (2D SLAM) - volně spojeno, synchronizace v čase

- $x = (\Omega^T p^T v^T)^T$... reorientace 3D stavu
 - $\Omega = (\phi, \theta, \psi)^T$... otáčení, stoupání, natočení
 - p, v ... pozice, rychlost platformy v navigačním rámci
 - $u = (\omega^T a^T)^T$... vstupní vektor pro inerciální měření
 - $\omega = (\omega_x, \omega_y, \omega_z)^T$... úhlová rychlost
 - $a = (a_x, a_y, a_z)^T$... zrychlení
- pohyb tuhého tělesa

$$\dot{\Omega} = E_{\Omega} \cdot \omega$$

$$\dot{p} = v$$

$$\dot{v} = R_{\Omega} \cdot a + g$$

- R_{Ω} ... matice směrových cosinů
- E_{Ω} ... mapování natočení těla na deriváty Eulerova úhlu
- g ... vektor gravitace
- integrovaná rychlost a pozice - signifikantní šum \rightarrow další informace o senzoru - porovnávání snímků (interiéry), snímač magnetického pole (směr), senzor barometrického tlaku (výška), měření rychlosti kol

4.3 2D SLAM

- mřížková mapa obsazenosti - reprezentace prostředí, osvědčená lokalizace robota
- transformace skenu na lokální stabilizovaný souřadnicový rámec odhadovanou polohou
- odhad orientace + sdružené hodnoty \rightarrow bodový oblak bodů - možnost předzpracování - odstranění odlehlých bodů
- tedy filtrace na základě koncového bodu z - při shodě skenu použity pouze koncové bodyprahové hodnoty skenovací roviny
- přístup k mapě - mřížková mapa obsazenosti - omezení přesnosti, neumožnění přímého

výpočtu interpolovaných hodnot a derivátů - interpolační schéma - submřížková přesnost buňky bilineárním filtrem

- - aproximace souřadnice P_m čtyřmi nejbližšími integerovými souřadnicemi ($P_{00} - P_{11}$)
- - vzorkovací body (buňky mřížky) od sebe na vzdálenost 1
- - porovnávání snímků - zarovnávání snímků vůči sobě nebo celé mapě
- - laserové skenery - malý šum, vysoká rychlost děláním snímků → možnost velmi přesného měření
- - - mnohem větší přesnost než odometrie, pokud vůbec je - v tomto případě nemáme vůbec
- - zarovnání koncových bodů s již známou mapou - není zapotřebí hledání spojení mezi koncovými body - porovnání se všemi předchozími skeny
- - hledání transformace s nejlepším sladěním skenu s mapou

$$\xi^* = \operatorname{argmin}_{\xi} \sum_{i=1}^n [1 - M(S_i(\xi))]^2$$

- - $M(P_m)$... hodnota obsazenosti
- - $S_i(\xi)$... souřadnice koncového bodu $s_i = (s_{i,x}, s_{i,y})^T$
- - ξ ... souřadnice robota
- - $M(S_i(\xi))$... hodnota mapy v souřadnicích $S_i(\xi)$ - - odhad $\Delta\xi$ - optimalizace chyby měření podle

$$\sum_{i=1}^n [1 - M(S_i(\xi + \Delta\xi))]^2 \rightarrow 0$$

- reprezentace map s více rozlišeními - riziko dosahu pouze lokálního minima - tímto se riziko zmírňuje - více mřížkových map vždy s polovičním rozlišením oproti předchozí
- uložených více map, součastné aktualizace odhady pozice generovaných zarovnávacím procesem
- - konzistence map napříč stupnicemi, vyhnutí se převzorkování
- - zarovnávání skenů na nejvyšší mapě, odhad pozice poté pro všechny ostatní - okamžitá dostupnost hrubých zrnitých map - dobré pro odhad trasy

4.4 3D State Estimation

- odhad úplného 3D stavového vektoru
- navigační filtr - 100 Hz - asynchronní aktualizace s pozicí z porovnávače a dalších informací ze senzorů jakmile přijdou
- navigační filtr - EKF - odhad 6D pozice - rozšíření ještě o náklon gyroskopů a akcelerometry
- - nelineární filtr, inerciální měření se berou jako známé vstupy systému
- - aktualizace rychlosti a pozice integrací zrychlení
- - aktualizace pseudo-nulové rychlosti - zabránění nezávislému růstu odhadu stavu pokud nejsou k dispozici měření - při dosažení odchylky určité prahové hodnoty - zajištění stability
- - pro odhad potřeba barometr, snímač rozsahu
- - integrace SLAM - 2D SLAM + 3D EKF - komunikace v obou směrech - nesynchronizovány, EKF větší frekvence obnovování
- - odhadovaná pozice EKF počáteční odhad pro optimalizaci porovnávání - nebo integrace odhadované rychlosti a úhlové rychlosti
- - opačně - kovarianční křížovatka (CI - covariance intersection) - spojení pozice ze SLAM

s celkovým odhadovaným stavem